

Estrutura de Dados

Augusto Guerra de Lima

Universidade Federal de Minas Gerais

Rascunho, fevereiro de 2024



Sumário

| | | |
|----------|--|----------|
| 1 | Complexidade de algoritmos | 4 |
| 1.1 | Crescimento assintótico de funções | 4 |
| 1.1.1 | Notação O | 5 |
| 1.1.2 | Notação Ω | 6 |
| 1.1.3 | Notação Θ | 7 |
| 1.1.4 | Notação o e ω | 8 |
| 1.2 | Identities de notação assintótica | 9 |
| 1.3 | O básico das regras de cálculo de complexidade . . . | 10 |
| 1.3.1 | Constantes | 11 |
| 1.3.2 | Laços de iteração | 11 |
| 1.3.3 | Fases | 14 |
| 1.3.4 | Várias variáveis | 15 |
| 1.3.5 | Recursão | 16 |
| 1.4 | Classes de complexidade | 17 |
| 1.4.1 | Lista de classes de complexidade | 17 |
| 1.5 | Pior caso, melhor caso e caso médio | 18 |

Prefácio

Este texto tem como propósito primordial (1) atender à necessidade de um material que apresente os tópicos abordados na disciplina de *Estrutura de Dados* de forma organizada e (2) oferecer suporte a estudantes que não tenham cursado a disciplina de *Matemática Discreta*, promovendo um encontro mais suave com os tópicos em matemática do conteúdo.

O texto está sendo aprimorado, e ficarei grato por qualquer sugestão ou comentário que você (leitor) possa enviar para o e-mail: augustoguerradelima@proton.me.

Belo Horizonte, fevereiro de 2024
Augusto Guerra de Lima

1 Complexidade de algoritmos

Antes de tudo, uma pergunta simples: Quantas comparações o laço de iteração abaixo deve fazer até parar?

```
for ( i := 0; i < n; i ++)
```

O laço realiza $n + 1$ comparações e repete n vezes. Esse tipo de contagem é importante para determinar a complexidade de um algoritmo, isso será feito junto de uma notação matemática chamada **notação assintótica**.

Tempo de execução, armazenamento e robustez são algumas características que determinam a qualidade de um algoritmo.

A **complexidade do tempo de execução** de um algoritmo é avaliada para estimar sua eficiência antes da implementação. A eficiência é representada por uma função que recebe o tamanho da entrada do algoritmo como parâmetro.

1.1 Crescimento assintótico de funções

A **análise assintótica** avalia o comportamento de uma função para valores de parâmetros *significativamente grandes*. Por exemplo, ao ver a expressão $n^2 + 10$ é comum pensar em valores pequenos de n , a análise assintótica se preocupa com valores enormes de n onde a constante 10 por exemplo, não faria diferença e o termo n^2 dominaria assintoticamente o crescimento da função.

As notações utilizadas para descrever complexidade são definidas em termos de funções cujos domínios são o conjunto dos números inteiros não negativos. Definiremos que $\mathbb{N}_0 = \{0, 1, 2, \dots\}$ e \mathbb{R}^+ como o conjunto dos números reais não negativos.

Sejam f e g funções tais que a taxa de crescimento de f é maior que a de g , podemos denotar $g \prec f$.

Antes de introduzir a notação assintótica, vamos avaliar um exemplo preliminar.

Exemplo 1 (Comparando funções)

Sejam f e g funções definidas no conjunto dos números inteiros não negativos, para comparar o comportamento assintótico de g e f , é preciso encontrar uma constante k tal que $g(n) \leq kf(n)$ para todo n suficientemente grande (escreveremos $n \geq n_0$). Isto é, encontrar constantes k e n_0 .

Sabendo $g(n) = \lceil \frac{n}{2} \rceil + 10$ e $f(n) = n$, encontrar k e n_0 tais que $g(n) \leq kf(n), \forall n \geq n_0$.

$$\left\lceil \frac{n}{2} \right\rceil \leq kn; \quad \left\lceil \frac{n}{2} \right\rceil \leq \frac{n}{2} + 11 \leq \frac{n}{2} + \frac{n}{2} = n.$$

Se $k = 1$ e $n_0 = 21$, por exemplo, então $f(n_0) = \lceil \frac{21}{2} \rceil + 10 = 21$ e $g(n_0) = 21$ e uma solução foi encontrada. Podem haver mais soluções.

△

Exemplo 2 (Caso sem solução)

Se $g(n) = n^3$ e $f(n) = n^2$, encontrar k e n_0 tais que $g(n) \leq kf(n), \forall n \geq n_0$.

$$n^3 \leq kn^2 \Rightarrow n \leq k, \forall n \geq n_0.$$

É impossível que uma função linear seja sempre menor ou igual a uma constante, portanto não há solução.

△

1.1.1 Notação O

A notação $O(f(n))$ (O grande de f de n), é o **limite assintótico superior justo** é a mais utilizada para descrever a complexidade de um algoritmo. Para uma função $f(n)$, $O(f(n))$ é o conjunto de funções

$$O(f(n)) = \{g : \mathbb{N}_0 \rightarrow \mathbb{R}^+ : \exists k, n_0 > 0; 0 \leq g(n) \leq kf(n), \forall n \geq n_0\}.$$

$O(f(n)) = \{ \text{"Todas as funções que têm taxa de crescimento menor ou igual a } f(n) \}$.

Dizer $g(n) = O(f(n))$ é dar um limite superior para $g(n)$, ou seja, intuitivamente para todos os valores $n \geq n_0$, encontrar uma família de funções com taxa de crescimento maior que $g(n)$. A figura 1 mostra um exemplo gráfico.

Utilizando a notação O , muitas vezes é possível determinar o tempo de execução de um algoritmo apenas inspecionando sua estrutura global. Um laço de iteração que fizer $n + 1$ comparações por exemplo, tem tempo de execução $O(n)$.

Exemplo

Sejam $g(n) = 2n^2 + n$ e $f(n) = n^2$, é verdadeiro que $g(n) = O(f(n))$ ou melhor, $2n^2 + n = O(n^2)$.




Figura 1: $g(n) = O(f(n))$.

Substituindo na desigualdade e simplificando os termos

$$2n^2 + n \leq kn^2 \Rightarrow 2 + \frac{1}{n} \leq k \forall n \geq n_0$$

$k = 3$ e $n_0 = 1$ satisfazem $g(n) = O(f(n))$. Basta substituir os valores na desigualdade e verificar

$$2n^2 + n \leq 3n^2 \Rightarrow n \leq n^2$$

A desigualdade é verdadeira para todo $n \geq 1$, em outras palavras $n_0 = 1$.

△

1.1.2 Notação Ω

A notação $\Omega(f(n))$ (Ômega de f de n), é o **limite assintótico inferior justo**. Nesse caso, dizer $g(n) = \Omega(f(n))$, significa que existe uma constante k tal que $0 \leq kf(n) \leq g(n)$ para todo $n \geq n_0$. Para uma função $f(n)$, $\Omega(f(n))$ é o conjunto de funções

$$\Omega(f(n)) = \{g : \mathbb{N}_0 \rightarrow \mathbb{R}^+ : \exists k, n_0 > 0; 0 \leq kf(n) \leq g(n), \forall n \geq n_0\}.$$

$\Omega(f(n)) = \{\text{"Todas as funções que têm taxa de crescimento maior ou igual a } f(n)\}$.

É importante notar que $g(n) = O(f(n)) \Leftrightarrow f(n) = \Omega(g(n))$. Essa propriedade é chamada de **simetria de transposição**.

Dizer que a complexidade de tempo de execução de um algoritmo é $\Omega(f(n))$ significa que seu tempo de execução será no mínimo $kf(n)$ para uma entrada de tamanho $n \geq n_0$.




Figura 2: $g(n) = \Omega(f(n))$.

Exemplo

Seja $f(n) = 2n^2$, verifique se $f(n) = \Omega(n^2)$, $f(n) = \Omega(n \log(n))$ e $f(n) = \Omega(n)$, utilizando a definição de taxa de crescimento.

Como $n \prec n \log(n) \prec n^2 \approx 2n^2$, então é possível dizer que $2n^2 = \Omega(n^2)$, $2n^2 = \Omega(n \log(n))$ e $2n^2 = \Omega(n)$.

△

1.1.3 Notação Θ

$g(n) = \Theta(f(n))$ (g de n é theta de f de n) significa que $f(n)$ é o **limite assintótico restrito** de $g(n)$, existem constantes k_0 e k_1 de forma que $0 \leq k_0 f(n) \leq g(n) \leq k_1 f(n)$, $\forall n \geq n_0$. Ou seja, o conjunto de funções

$$\Theta(f(n)) = \{g : \mathbb{N}_0 \rightarrow \mathbb{R}^+ : \exists k_0, k_1, n_0 > 0; 0 \leq k_0 f(n) \leq g(n) \leq k_1 f(n), \forall n \geq n_0\}.$$

Se $g(n) = \Theta(f(n))$, então $g(n) = O(f(n))$ e $f(n) = \Omega(g(n))$, a recíproca também é válida.

Além disso $g(n) = \Theta(f(n)) \Leftrightarrow f(n) = \Theta(g(n))$.

Exemplo

Mostre que $\frac{n^2}{2} - 3n = \Theta(n^2)$.

O problema consiste em encontrar $k_0, k_1, n_0 > 0$ tais que $k_0 n^2 \leq \frac{n^2}{2} - 3n \leq k_1 n^2 \forall n \geq n_0$.

Dividindo a expressão por n^2

$$k_0 \leq \frac{1}{2} - \frac{3}{n} \leq k_1 \quad \forall n \geq n_0.$$

Para a inequação da direita $\frac{1}{2} - \frac{3}{n} \leq k_1$, escolhendo $n_0 = 1$ e $k_1 = \frac{1}{2}$ encontra-se $\frac{1}{2} - 3 \leq \frac{1}{2}$, satisfazendo a primeira desigualdade.




Figura 3: $g(n) = \Theta(f(n))$.

Na segunda inequação $\frac{1}{2} - \frac{3}{n} \geq k_0$, se escolhermos $k_0 = \frac{1}{14} < k_1$ e $n_0 = 7$ a desigualdade é satisfeita.

Dessa forma, para $n \leq 7$ ou seja $n_0 = 7$, são escolhidas $k_0 = \frac{1}{14}$ e $k_1 = \frac{1}{2}$, e pela definição $\frac{n^2}{2} - 3n = \Theta(n^2)$.

△

1.1.4 Notação o e ω

As duas últimas notações são usadas para **limites assintoticamente não justos**, o para superiores e ω para inferiores.

Por exemplo, seja λ uma constante maior que zero, $\lambda n^2 = O(n^2)$ mas $\lambda n^2 \neq o(n^2)$. Ademais, $\lambda n = o(n^2)$.

$$o(f(n)) = \{g : \mathbb{N}_0 \rightarrow \mathbb{R}^+ : \exists k, n_0 > 0; 0 \leq g(n) < kf(n), \forall n \geq n_0\}.$$

Os limites abaixo revelam que à medida que $n \rightarrow \infty$, $g(n)$ torna-se insignificante em relação à $f(n)$.

$$\lim_{n \rightarrow \infty} \frac{f(n)}{g(n)} = \infty; \quad \lim_{n \rightarrow \infty} \frac{g(n)}{f(n)} = 0.$$

De forma análoga, $\lambda n^2 = \omega(n)$ mas $\lambda n^2 \neq \omega(n^2)$, contudo $\lambda n^2 = \Omega(n^2)$.

$$\omega(f(n)) = \{g : \mathbb{N}_0 \rightarrow \mathbb{R}^+ : \exists k, n_0 > 0; 0 \leq kf(n) < g(n), \forall n \geq n_0\}.$$

Os limites abaixo revelam que à medida que $n \rightarrow \infty$, $f(n)$ torna-se insignificante em relação à $g(n)$.




Figura 4: Conjunto de funções nas notações.

$$\lim_{n \rightarrow \infty} \frac{g(n)}{f(n)} = \infty; \quad \lim_{n \rightarrow \infty} \frac{f(n)}{g(n)} = 0.$$

É claro que as notações o e ω respeitam a identidade de simetria de transposição entre si.

Exemplo

Prove que $2n = o(n^2)$ mas $2n^2 \neq o(n^2)$.

$$\lim_{n \rightarrow \infty} \frac{2n}{n^2} = 0; \quad \lim_{n \rightarrow \infty} \frac{2n^2}{n^2} = 2.$$

Assim, $2n = o(n^2)$ é uma expressão válida para todos os valores de $k > 0$ e $n_0 = 1$ e como o limite no segundo caso não tende a zero, não existem valores $k > 0$ e n_0 que satisfaçam a definição da notação o , portanto $2n^2 \neq o(n^2)$.

△

1.2 Identidades de notação assintótica

As comparações assintóticas respeitam algumas identidades, considerando funções f e g assintoticamente positivas.

Reflexividade

$$f(n) = \Theta(f(n)).$$

Aplica-se também as notações O e Ω .

Transitividade

$$f(n) = \Theta(f(n)), \quad g(n) = \Theta(h(n)) \Rightarrow f(n) = \Theta(h(n)).$$

Aplica-se para todas as outras notações.

Simetria

$$f(n) = \Theta(g(n)) \Leftrightarrow g(n) = \Theta(f(n)).$$

Outras

$$O(n + m) = O(n) = O(m).$$

$$O(kn) = kO(n) = O(n).$$

Quando a notação assintótica é utilizada sozinha no lado direito de uma equação como em $n = O(n)$, o sinal de $=$ não representa igualdade e sim que a função $f(n) = n \in O(n)$, sendo unidirecional, assim nunca se deve escrever coisas do tipo $O(n) = n$.

Em equações como a apresentada abaixo $=$ representa igualdade.

$$n^2 + n + 10 = n^2 + \Theta(n).$$

Na equação supracitada, a notação assintótica pode ser interpretada como uma função que não é importante definir precisamente.

$$n^2 + n + 10 = n^2 + f(n).$$

A função $f(n)$ pertence ao conjunto $\Theta(n)$. Nesse caso, $f(n) = n + 10$ que de fato pertence a $\Theta(n)$.

1.3 O básico das regras de cálculo de complexidade

Como mencionado, a partir de uma inspeção do algoritmo, antes de sua implementação é possível estimar sua complexidade e colocá-la em termos de $O(f(n))$. Algumas estruturas no algoritmo podem ter suas complexidades estimadas rapidamente, outros algoritmos requerem técnicas mais avançadas. O cálculo do número de operações é um problema de contagem, abaixo alguns exemplos simples utilizando os princípios fundamentais da contagem.

Deve-se sempre procurar expressar o custo assintótico de algoritmos da forma mais precisa possível. No caso da notação O , essa precisão envolve (1) expressar o limite superior firme do custo assintótico do algoritmo e (2) indicar o caso do algoritmo para o qual esse custo se aplica.

Exemplo

O algoritmo para encontrar um elemento k em um vetor não ordenado de tamanho n tem custo $O(n)$ no pior caso. É possível dizer que no pior caso o algoritmo é $O(n^2)$, no entanto, esse custo não define um limite superior firme, que é $O(n)$ e a função $f(n) = n$ que deve ser usada.

△

1.3.1 Constantes

Exemplo

Operações aritméticas e atribuições levam um custo constante e distinto para serem realizadas. Por exemplo no pseudocódigo abaixo, cada linha tem um custo constante k_0 , k_1 e k_2 respectivamente. Frequentemente, consideramos todas com custo 1, mas na realidade isso é falso, elas possuem custos distintos.

```
int a:= 2
int b:= 7
int a:=a+b
```

A chamada **função de complexidade**, são os valores explícitos $f(n) = k_0 + k_1 + k_2 = k_3$ ou $f(n) = 3$, a **ordem de complexidade** é a ordem expressa em notação assintótica apenas com os termos dominantes, ignorando constantes e termos assintoticamente irrelevantes, $f(n) = O(1)$.

△

1.3.2 Laços de iteração

Exemplo 1

O algoritmo representado por pseudocódigo abaixo está somando elementos de um vetor V utilizando um laço de iteração *for*.

```
int soma(V, n)
{
    int s:= 0
    for (i:=0; i<n; i++)
        s:=s+V[i]

    return s
}
```

Primeiramente vamos estimar a complexidade do tempo de execução do algoritmo.

(1) Atribuir o valor 0 para s tem custo 1;

(2) No laço de iteração *for* $i := 0$ tem custo 1, $i++$ é feito n vezes e a comparação $i < n$, $n + 1$ vezes, é possível então dizer que o *for* tem custo $2n + 2$, no entanto o importante é a operação mais realizada, a de *comparação* $i < n$, com custo $n + 1$;

(3) A *atribuição* $s := s + V[i]$, dentro do laço de repetição é no total realizada n vezes, portanto tem custo n .

Somando as complexidades em (1), (2) e (3) obtemos $g(n) = 2n + 3$. E podemos dizer $g(n) = O(n)$.

A complexidade de espaço nesse algoritmo também pode ser estimada.

(1) As variáveis n , s e i tem custo 1, somando temos 3;

(2) V é um vetor que armazena n variáveis e tem custo n ;

Somando as complexidades de (1) e (2), obtemos $S(n) = n + 3$ e $S(n) = O(n)$.

△

Exemplo 2 (Laços aninhados)

Um caso extremamente comum são os **laços de iteração aninhados**.

```
for ( i := 0; i < n; i++)  
    for ( j := 0; j < n; j++)  
        //procedimento
```

Note que a cada iteração do primeiro laço, o segundo executa $n + 1$ comparações, mas como o primeiro laço repete n iterações, obtemos $g(n) = n(n + 1) = n^2 + n$ e $g(n) = O(n^2)$.

Generalizando, sejam i_0, i_1, \dots, i_{k-1} , k variáveis distribuídas entre k laços de iteração, onde $i_k < n$ e i_k++ para todo laço de iteração, ignorando outros procedimentos, podemos estimar a complexidade como $g(n) = O(n^k)$.

△

Exemplo 3

Nos laços de iteração aninhados abaixo, repare a comparação $j < i$.

```
for ( i := 0; i < n; i++)  
    for ( j := 0; j < i; j++)  
        //procedimento
```

-
- (1) O primeiro laço com o iterador i realiza $n + 1$ comparações;
(2) No segundo laço j varia de 0 a k a cada vez que $i := k$, sendo $0 \leq k \leq n$. Dessa forma, o procedimento é executado $0 + 1 + 2 + 3 + \dots + n = \frac{n(n+1)}{2}$ vezes.

Sendo assim, a complexidade do algoritmo é $O(n^2)$.

△

Exemplo 4 (Passos diferentes)

Repare no passo do laço de repetição abaixo $i := i + k$. Onde k é alguma constante

```
for ( i := 0; i < n; i := i + k )
    //procedimento
```

Se i é incrementado de k em k , o procedimento é executado $\frac{n}{k}$ vezes e o laço realiza $\frac{n}{k} + 1$ comparações. A complexidade do algoritmo é $O(n)$.

△

Exemplo 5 (Condição de parada)

Há casos em que o laço de iteração não é tão evidente, podendo ser o caso de inspecionar a condição de parada, ou seja, a condição que deve ser satisfeita para o laço de iteração parar de executar as operações dentro dele. No exemplo abaixo a condição de parada é $j > n$.

```
int j := 0
for ( i := 0; j <= n; i++)
    j := j + i
```

Primeiramente, qual o comportamento da variável j a medida que i é incrementada ?

- (1) O comportamento de j é descrito na tabela abaixo;

| i | j |
|---|--------------------------------------|
| 0 | 0 |
| 1 | 0 + 1 = 1 |
| 2 | 0 + 1 + 2 = 3 |
| k | 0 + 1 + ... + k = $\frac{k(k+1)}{2}$ |

(2) Vamos assumir que a condição de parada foi alcançada, ou seja $j > n$. Isso significa que para algum valor $i = k$, $j > n$ e como $j = \frac{k(k+1)}{2} > n$;

(3)

$$\frac{k(k+1)}{2} = \frac{k^2 + k}{2} > n \Rightarrow k^2 + k > 2n \Rightarrow k^2 > n \Rightarrow k > \sqrt{n}.$$

A complexidade desse algoritmo é $O(\sqrt{n})$.

△

Exemplo 6

```
for ( i:=0; i<n; i:=i*2)
    //procedimento
```

(1) A variável i cresce em potências de base 2 e assume um valor 2^k ;

(2) Assumindo que a condição de parada $i \geq n$ foi atingida, então $2^k \geq n$ e quando $2^k = n$, obtemos $k = \log_2(n)$;

(3) O procedimento é executado $\lceil \log_2(n) \rceil$ vezes.

A complexidade do algoritmo é $O(\log(n))$.

△

Exemplo 7

```
for ( i:=0; i*i<n; i++)
    //procedimento
```

A condição de parada do laço de iteração é $i^2 \leq n$, o algoritmo tem complexidade $O(\sqrt{n})$.

△

1.3.3 Fases

Se um algoritmo possui diversas fases, a complexidade do tempo de execução será a da fase com maior complexidade.

Exemplo 1

No pseudocódigo abaixo, o laço com maior complexidade é o segundo, $O(n^2)$. A complexidade do algoritmo é $O(n^2)$.

```

for (i:= 0; i<n; i++)
    // procedimento

for (i:= 0; i<n; i++)
    for (j = 0; j<n; j++)
        //procedimento

```

△

Exemplo 2 (Dependência de fases)

No pseudocódigo abaixo, a variável p cria uma dependência entre os laços, e embora eles não estejam aninhados, a complexidade do procedimento executado no segundo laço depende da complexidade do primeiro.

```

int p:= 0
for (i:= 0; i<n; i=i*2)
    p++

for (i:= 0; i<p; i=i*2)
    //procedimento

```

(1) A variável p é incrementada $\lceil \log_2(n) \rceil$ vezes no primeiro laço de iteração;

(2) O procedimento do segundo laço de repetição é executado $\log_2(p) = \log_2(\log_2(n))$ vezes.

A complexidade nessa caso é $O(\log \log(n))$.

△

1.3.4 Várias variáveis

Em alguns casos a complexidade pode depender de mais de uma variável e sua ordem de magnitude estará em função dessas variáveis.

Exemplo

```

for (i:= 0; i<n; i++)
    for (j:= 0; m; j++)
        //procedimento

```

Nesse caso a complexidade é $O(nm)$.

△

1.3.5 Recursão

A complexidade do tempo de execução de funções recursivas depende do número de chamadas e da complexidade de cada chamada.

Exemplo 1

```
fatorial(n)
{
    if (n=0)
        return 1

    n*fatorial(n-1)
}
```

(1) Cada chamada faz uma comparação e tem complexidade $O(1)$ (constante);

(2) Dada uma entrada n a função faz $n - 1$ chamadas recursivas;

A complexidade total é o produto da complexidade de cada chamada e da complexidade da quantidade de chamadas, dessa forma a complexidade é $O(n)$.

△

Exemplo 2

```
void funcao(n)
{
    if (n=1)
        return

    funcao(n-1)
    funcao(n-1)
}
```

(1) Cada função gera duas chamadas do mesmo tipo, as próximas duas fazem juntas quatro chamadas, as próximas quatro, oito e assim por diante;

(2) quando as chamadas chegam em $funcao(1)$ foram feitas 2^{n-1} chamadas.

A complexidade é $O(2^n)$.

△




Figura 5: Esboço, algumas funções da hierarquia.

1.4 Classes de complexidade

Na análise de algoritmos existem classes de complexidade muito comuns. Do ponto de vista assintótico a seguinte hierarquia de funções pode ser definida

$$1 \prec \log(\log(n)) \prec \log(n) \prec \sqrt[k]{n} \prec n \prec n \log(n) \prec n^k \prec n^{\log(n)} \prec k^n \prec n! \prec n^n.$$

Onde k é uma constante maior que zero.

A hierarquia de funções supracitadas indica que as funções mais a direita tem uma **ordem de crescimento** ou **ordem de magnitude** maior. Ou seja, quando $n \rightarrow \infty$, assumem valores mais significativos.

1.4.1 Lista de classes de complexidade

$O(1)$ Dizemos que a complexidade do tempo de execução é **constante**, geralmente quando é utilizada uma formula fechada, não dependendo do tamanho da entrada;

$O(\log(n))$ A complexidade é dita **logarítmica**, geralmente o tamanho da entrada é dividido por um fator, um exemplo de algoritmo é a **busca binária**;

$O(\sqrt{n})$ É uma complexidade de **raiz quadrada** que fica aproximadamente no meio da entrada já que $\sqrt{n} = \frac{\sqrt{n}}{1}$;

$O(n)$ Executa em tempo **linear**, geralmente é o melhor caso de complexidade possível de alcançar, já que muitas vezes é preciso acessar n posições pelo menos uma vez;

$O(n \log(n))$ A complexidade **$n \log(n)$** é um forte indício de que a entrada está sendo ordenada ou que há uma **estrutura de dados** com operações de complexidade em tempo de execução de $O(\log(n))$;

$O(n^2)$ Um algoritmo com complexidade de tempo de execução **quadrática** geralmente aparece em laços de iteração aninhados;

$O(n^3)$ É dito um algoritmo **cúbico**;

$O(2^n)$ Em geral os casos k^n são chamados **exponenciais**, no entanto 2^n é um caso particular, pois é o número de subconjuntos de um conjunto discreto finito, o que pode revelar que o algoritmo itera por todos os subconjuntos da entrada;

$O(n!)$ Uma complexidade **fatorial** geralmente indica que o algoritmo itera por todas as permutações da entrada.

1.5 Pior caso, melhor caso e caso médio

Um mesmo algoritmo pode desempenhar diferentes complexidades dependendo da entrada. O melhor caso de uma busca em um vetor por exemplo, ocorre quando o primeiro elemento é o elemento procurado, e o pior caso quando o elemento não se encontra no vetor.

O algoritmo de ordenação *quicksort* por exemplo, apresenta seu caso médio com complexidade $O(n \log(n))$ e seu pior caso com complexidade $O(n^2)$.

O cálculo de complexidade do caso médio é bem mais complicado, Ele requer a probabilidade P da ocorrência de uma entrada.

Felizmente, na maioria da vezes, estamos interessados no pior caso de complexidade do algoritmo.